1주차 공부 내용 정리

교재 1-2장 | LLM의 발전과 AI Agent의 등장 | 팀 알아서할게

1주차에는 교재 1-2장을 읽고 LLM이 어떤 과정을 거쳐 지금의 모습이 되었는지, 그리고 LLM의 한계에서 AI Agent가 왜 등장했는지 정리했다. 범위는 LLM의 탄생과 발전, 멀티모달 LLM, 모델 규모 확장, 오픈소스 LLM, 추론 모델, AI Agent의 등장 여섯 주제다.

01 LLM의 탄생과 발전

언어 모델은 앞에 나온 단어를 보고 다음에 올 단어의 확률을 계산하는 모델이다. LLM도 기본 원리는 같고, 학습 데이터와 파라미터 수를 크게 늘려 문장 생성, 요약, 번역, 코드 작성처럼 여러 작업을 하나의 모델로 처리한다.

Transformer 이전

초기 언어 모델은 n-gram처럼 단어가 함께 나온 빈도를 세는 통계 방식이었다. 이후 RNN과 LSTM이 문장을 순서대로 읽으며 문맥을 기억하게 되었지만, 문장이 길어지면 앞부분 정보가 흐려지고 순차 계산이라 병렬 처리가 어려웠다.

Transformer와 사전학습 모델

2017년 Google이 발표한 Transformer는 self-attention으로 문장 안의 모든 단어 관계를 한 번에 계산한다. 긴 문맥을 다루기 쉬워졌고 GPU 병렬 처리가 가능해져서 큰 모델을 학습할 수 있게 되었다. 이 구조를 바탕으로 대량의 텍스트로 먼저 사전학습하고 작업별로 미세조정하는 방식이 자리 잡았다.

시기	모델	의미
2018	GPT-1, BERT	Transformer 기반 사전학습 모델. GPT는 decoder로 생성을, BERT는 encoder로 이해를 맡는다.
2019	GPT-2	15억 파라미터. 별도 학습 없이도 여러 작업을 어느 정도 수행했다.
2020	GPT-3	1,750억 파라미터. 프롬프트에 예시 몇 개만 넣어도 작업을 수행하는 few-shot 능력을 보였다.
2022.11	ChatGPT	RLHF로 사람의 선호에 맞춰 조정한 대화형 모델. LLM이 일반 사용자에게 널리 알려졌다.
2023.3	GPT-4	추론과 전문 시험 성능이 크게 올랐고 이미지 입력을 지원했다.

ChatGPT에서 중요한 변화는 모델 크기보다 정렬 방식이었다. 사전학습만 한 모델은 문장을 이어 쓸 뿐 지시를 잘 따르지 않는데, instruction tuning과 RLHF를 거치면서 질문에 답하고 지시를 따르는 assistant 형태가 되었다.

02 멀티모달 LLM

멀티모달 LLM은 텍스트뿐 아니라 이미지, 음성, 영상을 함께 입력받고 처리하는 모델이다. 사진 속 상황을 설명하거나 표와 그래프를 읽고, 음성으로 바로 대화하는 일이 가능해졌다.

- CLIP(2021)은 이미지와 텍스트를 같은 embedding 공간에 맞추는 방식을 보여 주었고, 이후 멀티모달 모델의 기반이 되었다.
- GPT-4V(2023)와 LLaVA 같은 모델은 vision encoder가 만든 이미지 feature를 LLM이 읽을 수 있는 토큰으로 바꿔 넣는 구조를 썼다.
- Gemini(2023.12)와 GPT-4o(2024.5)는 처음부터 여러 모달리티를 함께 학습한 모델이다. GPT-4o는 음성 입력에 사람과 비슷한 속도로 답한다.

AI Agent 관점에서 멀티모달은 에이전트가 인식할 수 있는 환경을 넓힌다. 화면 캡처를 보고 버튼을 누르는 computer use 에이전트도 이미지 이해 능력이 있어야 가능하다.

03 모델 규모 확장

Scaling law

2020년 OpenAI의 Kaplan 등은 모델의 loss가 파라미터 수, 학습 데이터 양, 계산량이 늘어날수록 거듭제곱 법칙을 따라 꾸준히 줄어든다는 결과를 발표했다. 이 결과가 나온 뒤로 모델을 키우면 성능이 오른다는 예측을 근거로 대형 모델에 투자하는 흐름이 이어졌다.

Chinchilla

2022년 DeepMind의 Chinchilla 연구는 같은 계산량이라면 파라미터만 키우기보다 데이터도 함께 늘려야 한다고 보였다. 파라미터 하나당 약 20개 토큰이 적정 비율이고, 700억 파라미터의 Chinchilla가 2,800억 파라미터의 Gopher보다 성능이 좋았다. 이후 모델들은 크기를 무작정 키우지 않고 더 많은 데이터로 오래 학습하는 방향으로 바뀌었다.

규모가 커지면서 나타난 현상

- Emergent ability: 작은 모델에서는 거의 안 되던 산술, 다단계 추론 같은 능력이 일정 규모를 넘으면 나타난다는 관찰이다. 평가 지표를 어떻게 잡느냐에 따라 달라 보인다는 반론도 있다.
- Mixture of Experts(MoE): 전체 파라미터는 크게 두고 입력마다 일부 expert만 계산하는 구조다. Mixtral 8x7B, DeepSeek-V3 등이 이 방식으로 비용을 줄였다.

04 오픈소스 LLM

오픈소스 LLM은 모델 가중치를 공개해 누구나 내려받아 실행하고 수정할 수 있는 모델이다. 학습 데이터와 코드까지 모두 공개하는 경우는 드물어서, 가중치만 공개한 모델은 open-weight 모델이라고 구분해 부르기도 한다.

시기	모델	특징
2023.2	LLaMA	Meta가 연구용으로 공개. 오픈소스 LLM 생태계가 본격적으로 커진 계기가 되었다.
2023.7	Llama 2	상업적 이용을 허용해 기업 서비스에도 쓰이기 시작했다.
2023.9	Mistral 7B	작은 크기로 더 큰 모델에 가까운 성능을 냈다.

2024	Llama 3, Qwen2, EXAONE 3.0	오픈 모델 성능이 상용 모델과 비슷한 수준까지 올라왔다. EXAONE은 LG AI연구원이 공개한 한국어 특화 모델이다.
2025.1	DeepSeek-R1	추론 모델을 MIT 라이선스로 공개해 큰 관심을 받았다.

오픈소스 모델은 내부 서버에서 실행할 수 있어서 데이터를 외부로 보내기 어려운 기업에 적합하다. LoRA 같은 경량 파인튜닝과 양자화 기법이 함께 발전하면서 개인 GPU에서도 모델을 고쳐 쓰는 일이 가능해졌다. 반대로 운영 인프라와 안전성 관리는 직접 책임져야 한다.

05 추론 모델

추론 모델은 답을 바로 내지 않고 내부에서 생각하는 과정을 길게 거친 뒤 답하는 모델이다. 수학, 코딩, 과학 문제처럼 여러 단계를 거쳐야 하는 문제에서 기존 모델보다 정확도가 크게 높다.

- Chain-of-Thought(2022)는 프롬프트에서 단계별로 생각하라고 요청하면 추론 성능이 오른다는 기법이다. 추론 모델은 이 과정을 학습으로 모델 안에 넣은 형태다.
- OpenAI o1(2024.9)은 강화학습으로 긴 추론 과정을 만들도록 학습했다. 답하기 전에 계산을 더 쓸수록 성능이 오르는 test-time compute 확장을 보여 주었다.
- DeepSeek-R1(2025.1)은 강화학습만으로 추론 능력을 끌어올린 과정을 논문으로 공개했고, 이후 Claude, Gemini 등 주요 모델도 thinking 기능을 넣었다.

> Scaling law가 학습 단계에서 모델과 데이터를 키우는 방향이었다면, 추론 모델은 답을 만드는 단계에서 계산을 더 쓰는 방향이다. 에이전트가 계획을 세우고 결과를 점검하는 능력도 이 추론 능력에 크게 의존한다.

06 AI Agent의 등장

LLM은 성능이 좋아져도 질문 하나에 답 하나를 돌려주는 구조라서 실제 업무를 끝까지 처리하기에는 한계가 있었다.

LLM의 한계	AI Agent의 해결 방식
학습 시점 이후 정보를 모른다	검색 도구나 RAG로 최신 정보와 내부 문서를 가져온다
환각으로 틀린 내용을 그럴듯하게 말한다	외부 자료와 실행 결과로 답을 확인한다
계산, 파일 처리, 외부 시스템 조작을 못 한다	function calling으로 API, 코드 실행기 같은 도구를 호출한다
한 번 답하면 끝나고 이전 작업을 기억하지 못한다	목표를 단계로 나누고 메모리에 진행 상황을 저장하며 반복 실행한다

등장 과정

- ReAct(2022)는 LLM이 생각(Reasoning)과 행동(Acting)을 번갈아 하며 도구 결과를 보고 다음 행동을 정하는 방식을 제안했다.

- AutoGPT와 BabyAGI(2023.3-4)는 목표만 주면 LLM이 스스로 작업을 나누고 반복 실행하는 모습을 보여 주며 AI Agent라는 말을 널리 알렸다.
- OpenAI의 function calling(2023.6) 이후 모델이 도구를 정해진 형식으로 호출할 수 있게 되었고, LangChain과 LangGraph 같은 프레임워크가 에이전트 구현을 쉽게 만들었다.
- 2024-2025년에는 Claude computer use, OpenAI Operator, 코딩 에이전트처럼 실제 환경에서 작업하는 에이전트 제품이 나왔다.

정리하면 AI Agent는 LLM을 두뇌로 쓰고 도구, 메모리, 계획 기능을 붙여서 목표를 스스로 수행하는 시스템이다.
구성요소와 동작 방식은 3-4장에서 자세히 다룬다.

07 더 생각해 볼 질문

- Scaling law가 계속 성립한다면 추론 모델처럼 다른 방향의 확장이 왜 필요해졌는가? 학습 데이터로 쓸 고품질 텍스트가 부족해지고 학습 비용이 커지는 점이 이유로 꼽힌다.
- 오픈소스 모델로도 에이전트를 만들 수 있는가? 도구 호출을 지원하는 모델이 늘고 있지만, 긴 작업을 안정적으로 수행하는 능력은 아직 상용 모델과 차이가 있다.

참고 자료: 서지영, 랭체인 & 랭그래프로 AI 에이전트 개발하기, 길벗 / Vaswani et al., Attention Is All You Need, 2017 / Kaplan et al., Scaling Laws for Neural Language Models, 2020 / Hoffmann et al., Training Compute-Optimal Large Language Models, 2022 / Yao et al., ReAct, 2022 / DeepSeek-AI, DeepSeek-R1, 2025