생성적 적대 신경망(GAN)

Generative Adversarial Network

AID 논문 스터디 – 인공지능학과 박현아

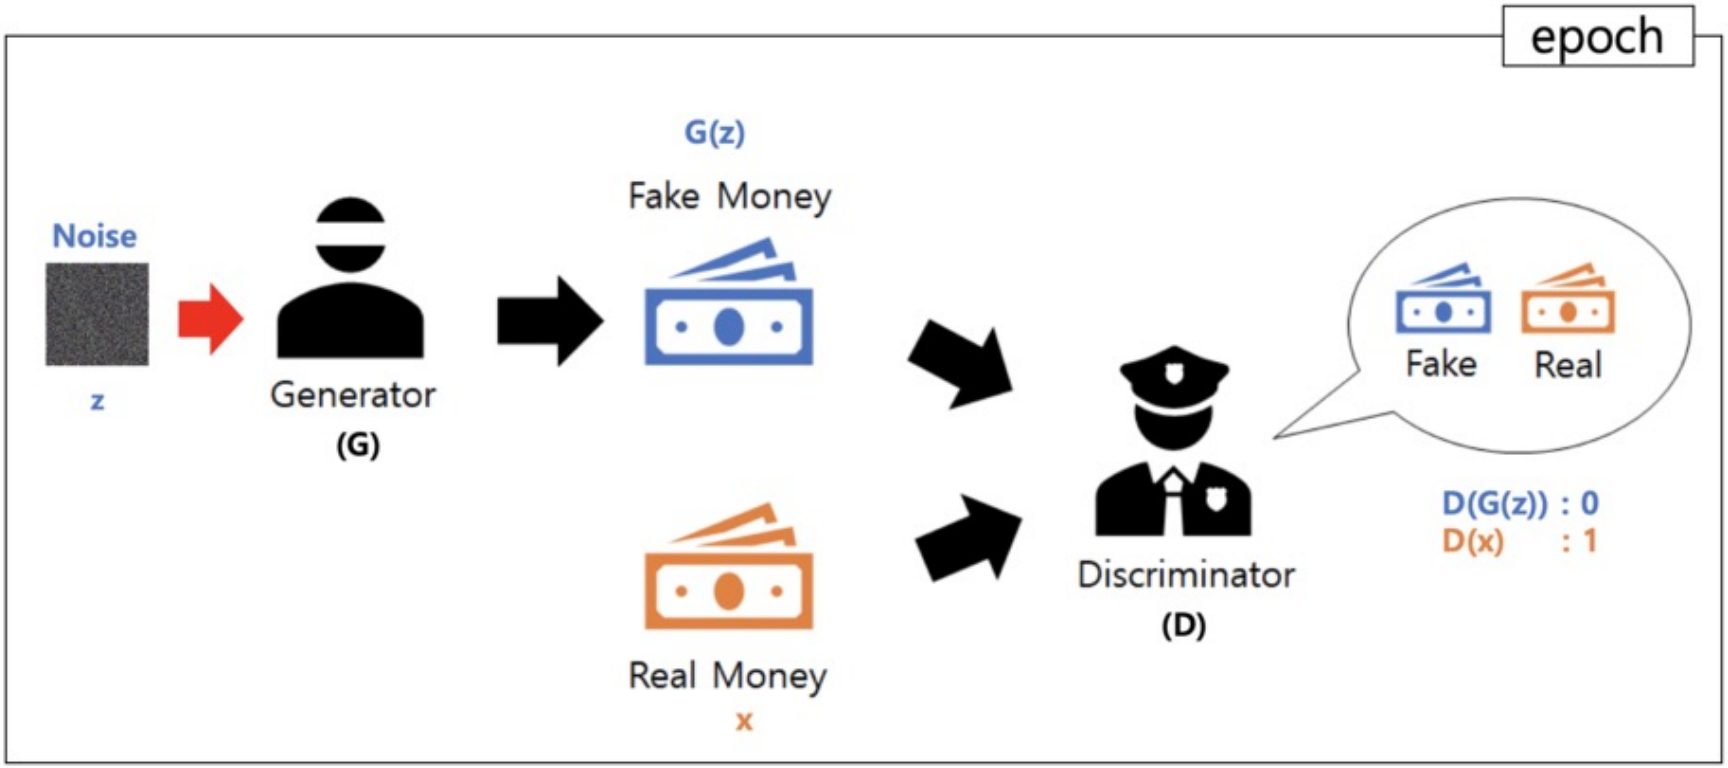
Abstract

- 적대적 과정을 통해 생성 모델을 추정하는 새로운 프레임워크
- 데이터 분포를 포착하는 생성 모델 G
- 주어진 샘플이 G가 아닌 실제 학습 데이터에서 왔을 확률을 추정하는 판별 모델 D
- 미니맥스 게임 : 최악의 경우 발생가능한 손실을 최소화하기

$$\min_G \max_D V(D,G) = \mathbb{E}_{x\sim p_{data}(x)}[\log D(x)] + \mathbb{E}_{z\sim p_z(z)}[\log(1-D(G(z)))]$$

Introduction

- 딥러닝은 클래스를 분류하는 판별 모델에 큰 성공을 거둠 ex) CNN, AlexNet 등 (당시 2014년)
- 그러나 생성 모델은 상대적으로 발전을 하지 못함
- 어려움들을 우회할 수 있는 새로운 생성 모델 추정 절차를 제안
- 위조지폐를 만드려는 위조범 집단과 이를 탐지하려는 경찰
- 위조와 진짜를 구별하지 못할 때까지 양쪽 모델을 개선함
- 다층 퍼셉트론을 이용하기 때문에 여러 모델과 최적화 알고리즘을 사용할 수 있음


epoch
Noise
z
Generator
(G)
G(z)
Fake Money
Real Money
x
Discriminator
(D)
Fake
Real
D(G(z)) : 0
D(x) : 1

생성 모델

- 생성 모델은 관측된 데이터를 가장 잘 설명하는 확률 분포를 찾는 모델이다!

- Ex) 동전 던지기에서, 관측 데이터 : [1, 1, 1, 0]
- $L(\theta) = \theta * \theta * \theta * (1 - \theta)$
- $L(\theta)$: 데이터가 나타날 확률 및 (로그) 우도 함수, θ : 앞면 확률

- $\text{Arg max}_\theta L(\theta) = 0.75$
- 미분해서 0이 되는 지점을 찾으면 $\theta = 0.75$

생성 모델

- Ex) 두가지 동전 중 하나를 선택, 결과는 앞면/뒷면만 확인
- z = {A, B} = 관측하지 못함 = 잠재 변수
- x = {앞, 뒤} = 직접 관측 가능
- $z \sim p_\theta(z)$: 매개변수 θ로 정의한 잠재 변수 z의 확률 분포
- $x \sim p_\theta(x|z)$: 잠재 변수 z가 주어졌을 때 x의 확률 분포

- 최종적으로 p(x=n)을 알고 싶다. 전체 확률의 법칙 계산!
- $p_\theta(x) = \sum_z p_\theta(z) * p_\theta(x|z)$
- 전체 확률 = 주변 확률 * 조건부 확률

생성 모델

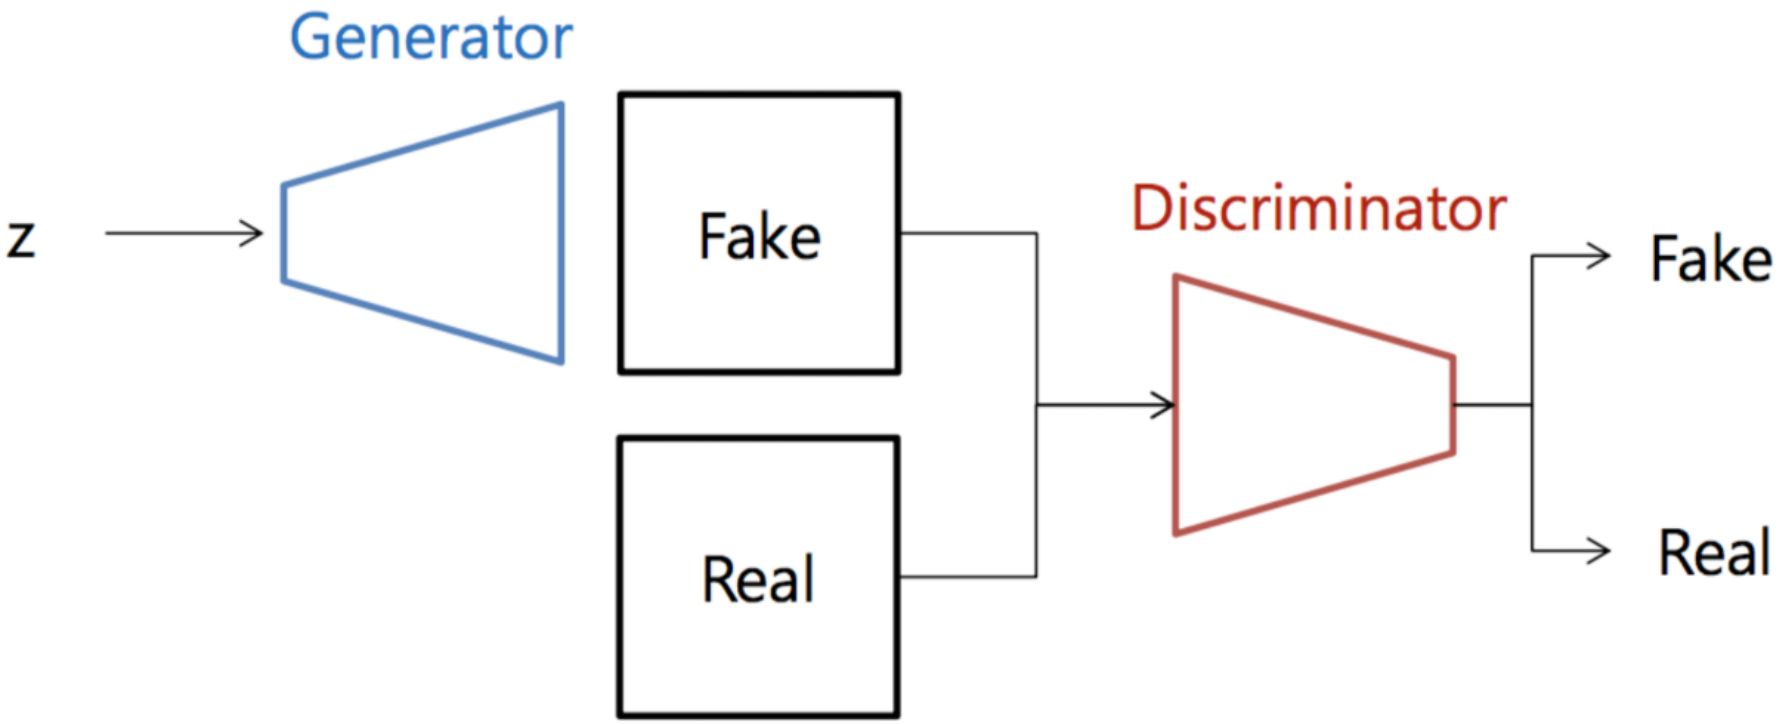
- 그러나 잠재 변수의 차원이 크거나 조건부 확률이 복잡해지면 계산을 수행하기 어렵다.
- GAN은 확률 분포를 명시적으로 계산하지 않고도 생성기를 통해 학습할 수 있는 새로운 접근 방식을 제안한다!

Related Work

- 잠재 변수를 포함하는 방향성 그래프 모델 : RBMs, DBMs
- 무방향 그래프 모델
- 마르코프 체인 몬테카를로(MCMC)의 혼합 문제
- 심층 신뢰 네트워크
- 스코어 매칭, 잡음 대조 추정
- 생성 기계 : 확률 네트워크 프레임워크

Adversarial Nets

- 적대적 모델링 프레임워크는 다층 퍼셉트론으로 정의해보자.
- z : 노이즈, p_z : 입력 잡음 변수에 대한 확률 분포
- G(z;θ_g) : 잡음을 데이터 공간으로 매핑, 매개변수를 가진 미분 가능한 다층 퍼셉트론
- p_g : G가 생성한 이미지들의 확률 분포
- D(x;θ_d) : x가 실제 데이터에서 나왔을 확률


Generator
z
Fake
Real
Discriminator
Fake
Real

Adversarial Nets

- 가치 함수 V(D, G)를 사용하는 두 모델의 미니맥스 게임

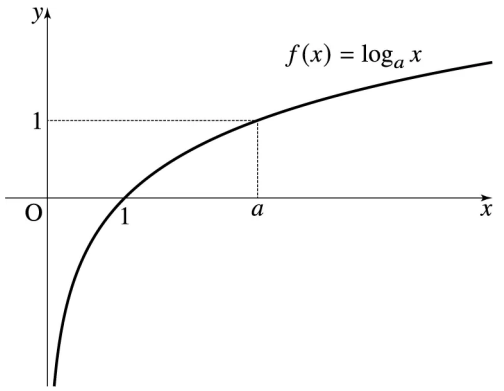
$$\min_G \max_D V(D,G) = \mathbb{E}_{\boldsymbol{x}\sim p_{\text{data}}(\boldsymbol{x})}[\log D(\boldsymbol{x})] + \mathbb{E}_{\boldsymbol{z}\sim p_{\boldsymbol{z}}(\boldsymbol{z})}[\log(1 - D(G(\boldsymbol{z})))]. \quad (1)$$

- D는 실제 이미지는 1로 가짜 이미지는 0으로 예측해야한다.
- 즉, V(D, G) = log D(x) + log(1-D(G(z))를 최대화 해야한다!
- G는 판별기가 가짜 이미지를 실제 이미지로 추정하도록 해야한다.
- 즉, V(D, G) = log(1-D(G(z))를 최소화 해야한다!

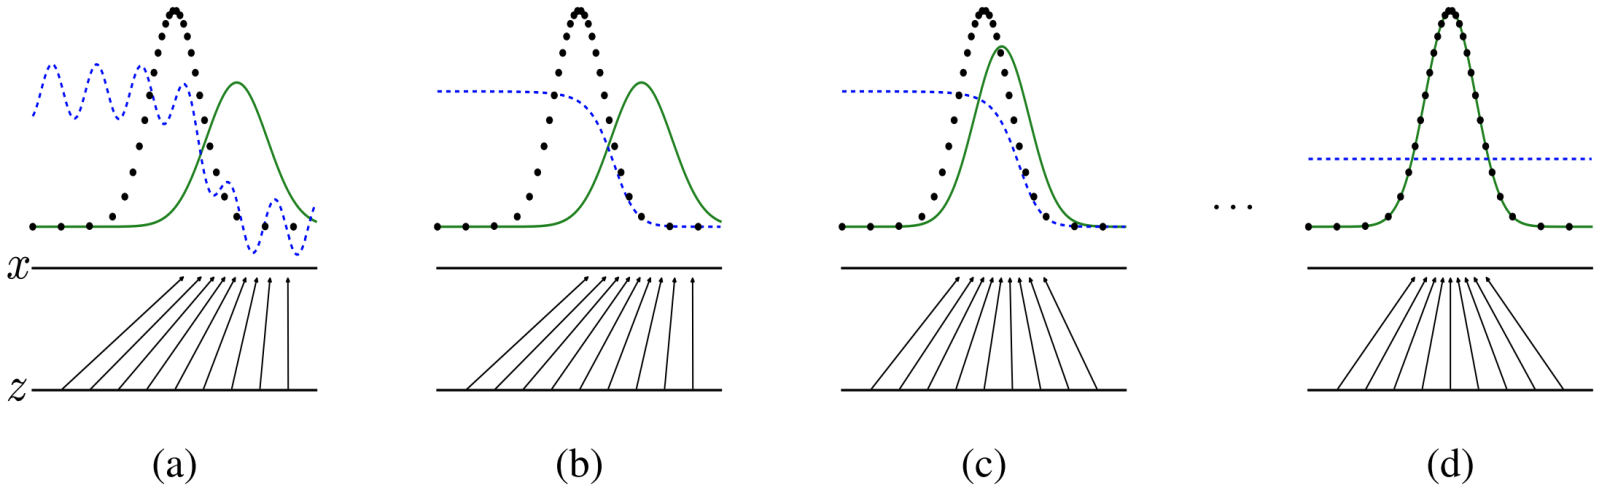
Adversarial Nets

- 학습 초기에는 G의 성능이 좋지 않기 때문에, 포화 상태 발생
- Ex) D(G(z)) = 0.001이면 log(1-D(G(z))은 작은 음수

- 따라서 log(1-D(G(z))를 최소화 하도록 학습시키는 대신, Log D(G(z))를 최대화 하도록 학습시킨다.
- L = - E_z [D(G(z))]
- 학습 초기에 더 강한 기울기를 제공할 수 있음!
- ex) D(G(z)) = 0.001이면 기울기는 -0.999



Adversarial Nets



- 검은색 : 실제 데이터 분포 p_data,
- 초록색 : 생성 데이터 분포 p_g
- 파란색 : 판별기 출력 D(x)

Theoretical Results

• GAN의 미니매치 SGD 학습 과정

1) 잡음 z와 실제 데이터 x를 각각 m개 추출, 가짜 데이터 생성
2) 판별기 D를 k번 학습 (G는 고정, D가 최적이 되도록)
3) 새로운 잡음 z를 m개 추출
4) 생성기 G를 1번 학습 (D는 고정)

위 과정을 반복

m은 미니배치의 크기

Algorithm 1 Minibatch stochastic gradient descent training of generative adversarial nets. The number of steps to apply to the discriminator, k, is a hyperparameter. We used $k = 1$, the least expensive option, in our experiments.

for number of training iterations **do**

  for k steps **do**

  - Sample minibatch of m noise samples $\{\boldsymbol{z}^{(1)}, \ldots, \boldsymbol{z}^{(m)}\}$ from noise prior $p_g(\boldsymbol{z})$.
  - Sample minibatch of m examples $\{\boldsymbol{x}^{(1)}, \ldots, \boldsymbol{x}^{(m)}\}$ from data generating distribution $p_{\text{data}}(\boldsymbol{x})$.
  - Update the discriminator by ascending its stochastic gradient:

$$\nabla_{\theta_d} \frac{1}{m} \sum_{i=1}^{m} \left[\log D\left(\boldsymbol{x}^{(i)}\right) + \log\left(1 - D\left(G\left(\boldsymbol{z}^{(i)}\right)\right)\right) \right].$$

  end for

  - Sample minibatch of m noise samples $\{\boldsymbol{z}^{(1)}, \ldots, \boldsymbol{z}^{(m)}\}$ from noise prior $p_g(\boldsymbol{z})$.
  - Update the generator by descending its stochastic gradient:

$$\nabla_{\theta_g} \frac{1}{m} \sum_{i=1}^{m} \log\left(1 - D\left(G\left(\boldsymbol{z}^{(i)}\right)\right)\right).$$

end for

The gradient-based updates can use any standard gradient-based learning rule. We used momentum in our experiments.

Theoretical Results

- 4.1 전역 최적성 : G가 고정되었을 때 최적 판별기 D*는

$$D_G^*(\boldsymbol{x}) = \frac{p_{data}(\boldsymbol{x})}{p_{data}(\boldsymbol{x}) + p_g(\boldsymbol{x})} \qquad \mathbb{E}_{\boldsymbol{x} \sim p_{\text{data}}} [-\log 2] + \mathbb{E}_{\boldsymbol{x} \sim p_g} [-\log 2] = -\log 4$$

- 최적 판별기를 대입하면 목적 함수는

$$C(G) = -\log(4) + 2 \cdot JSD\left(p_{\text{data}} \| p_g\right)$$

- JSD는 두 분포가 같을 때 0이므로, p_g = p_data에서 전역 최솟값 –log 4 달성
- 이때 최적 판별기 D(x) = 1/2

Theoretical Results

- 4.2 알고리즘의 수렴
- 충분한 모델 용량과 최적 판별기, 작은 업데이트를 가정하면 p_g는 p_data로 수렴
- 단, 실제 신경망에서는 수렴이 보장되지 않는다.

- JSD : KL Divergence를 이용해 두 확률 분포의 차이를 대칭적으로 측정하는 방법
- JSD는 항상 0 이상이며, 두 분포가 같을 때만 0

$$JSD(P\|Q) = \frac{1}{2}KL(P\|M) + \frac{1}{2}KL(Q\|M)$$

Theoretical Results

- 이 논문에서 제시하는 것은 두가지
- 1. 전역 최적성 (Global Optimality) : GAN 목적 함수가 가장 좋은 값을 가지는 상태가 정말 p_g = p_data인지 증명
- 2. 알고리즘의 수렴 (Convergence) : 충분한 조건이 주어졌을 때 학습 과정이 그 최적 상태로 수렴하는지 설명

Experiments

- MNIST, TFD, CIFAR-10으로 GAN을 학습시켰다.
- 생성기 G : ReLU계열+ Sigmoid 활성화 함수
- 판별기 D : Maxout 활성화 함수 + Dropout 학습
- Gaussian Parzen Window : 개별 데이터의 가우시안 커널 함수를 결합하여 확률 밀도 함수를 추정하는 방법
- 이는 추정값의 분산이 크고 고차원 공간에서 잘 작동하지 않는다는 한계가 존재
- GAN이 기존 방법으로 생성된 샘플보다 더 우수하다고 주장하지는 않음. 그러나 기존의 우수한 생성 모델들과 경쟁할만한 수준을 보여줌.

Experiments

Model	MNIST	TFD
DBN [3]	138 ± 2	1909 ± 66
Stacked CAE [3]	121 ± 1.6	$\mathbf{2110 \pm 50}$
Deep GSN [6]	214 ± 1.1	1890 ± 29
Adversarial nets	$\mathbf{225 \pm 2}$	$\mathbf{2057 \pm 26}$



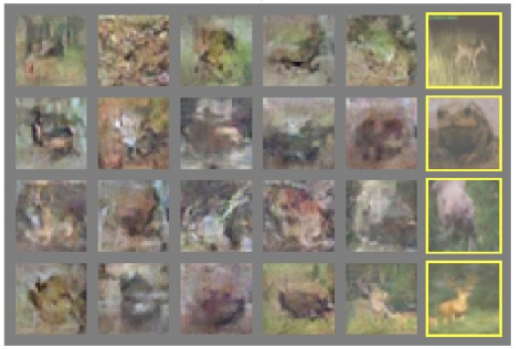
a)



b)



c)



d)





Experiments

	Deep directed graphical models	Deep undirected graphical models	Generative autoencoders	Adversarial models
Training	Inference needed during training.	Inference needed during training. MCMC needed to approximate partition function gradient.	Enforced tradeoff between mixing and power of reconstruction generation	Synchronizing the discriminator with the generator. Helvetica.
Inference	Learned approximate inference	Variational inference	MCMC-based inference	Learned approximate inference
Sampling	No difficulties	Requires Markov chain	Requires Markov chain	No difficulties
Evaluating $p(x)$	Intractable, may be approximated with AIS	Intractable, may be approximated with AIS	Not explicitly represented, may be approximated with Parzen density estimation	Not explicitly represented, may be approximated with Parzen density estimation
Model design	Nearly all models incur extreme difficulty	Careful design needed to ensure multiple properties	Any differentiable function is theoretically permitted	Any differentiable function is theoretically permitted

- GAN은 생성기와 판별기 사이의 학습 균형을 맞춰야함
- Helvetica Scenario 발생

Advantages and disadvantages

장점

- 마르코프 체인 및 근사 추론(MCMC) 불필요
- 역전파만으로 학습 가능
- 다양한 미분 가능한 신경망 구조 활용 가능

단점

- 생성 분포 p_g(x)를 명시적으로 계산하기 어려움
- 생성기 G와 판별기 D의 학습 균형 유지 필요
- 생성 결과의 다양성 감소 가능성 (Mode Collapse)

Conclusions and future work

- 여러가지 확장 가능성을 제공

- 1. 조건부 생성 모델 (Conditional GAN)
- 2. 잠재 변수 추정을 위한 근사 추론 네트워크 ex) x->z
- 3. 다양한 조건부 확률 분포 모델링 ex) 가려진 영역 생성
- 4. 준지도학습 (Semi-supervised Learning) -> 분류 작업에 유용한 특징을 학습하는 데 활용
- 5. 생성기와 판별기의 학습 효율 개선

Thank you for listening