3주차 공부 내용 정리

교재 4장 | AI Agent 구성요소, 동작 방식, 에이전트 유형 | 팀 알아서할게

3주차에는 교재 4장을 읽고 AI Agent를 이루는 구성요소와 동작 방식, 에이전트 유형을 정리했다. 구성요소마다 실제 서비스에서 어떤 형태로 쓰이는지를 함께 적었다.

01 AI Agent 구성요소

AI Agent는 LLM 하나로 이루어지지 않고 여러 구성요소가 함께 동작한다. OpenAI의 Lilian Weng이 2023년 글 LLM Powered Autonomous Agents에서 LLM을 중심에 두고 계획, 메모리, 도구 사용을 붙인 구조를 제시했고, 교재의 구성도 이와 비슷하다.

구성요소	역할	예시
인지	사용자 입력, 문서, 이미지, 도구 실행 결과처럼 환경에서 들어오는 정보를 받는다.	채팅 입력, 화면 캡처, API 응답
두뇌(LLM)	들어온 정보를 이해하고 다음에 할 일을 판단한다.	GPT, Claude, Gemini
메모리	대화 내용과 작업 결과를 저장해 두고 판단할 때 꺼내 쓴다.	대화 기록, vector DB
계획	큰 목표를 작은 단계로 나누고 순서를 정한다.	할 일 목록 작성, 계획 수정
도구	LLM이 혼자 못 하는 일을 대신 수행한다.	웹 검색, 계산기, 코드 실행기
행동	판단한 결과를 실제로 실행해 환경을 바꾼다.	메일 발송, 파일 저장, 답변 출력

02 메모리

단기 메모리

단기 메모리는 현재 작업 중인 대화와 중간 결과를 LLM의 context window 안에 담아 두는 방식이다. 바로 쓸 수 있지만 context window 크기를 넘으면 앞부분을 잘라내거나 요약해야 한다.

장기 메모리

장기 메모리는 대화가 끝난 뒤에도 남겨 두는 정보로, 보통 외부 저장소에 넣어 두고 필요할 때 검색해서 불러온다. 사용자 취향, 지난 작업 결과, 자주 쓰는 절차 같은 정보가 여기에 들어간다.

종류	저장하는 내용
Episodic	과거에 겪은 일과 그 결과. 예를 들어 지난번 예약이 실패한 이유
Semantic	사실과 지식. 예를 들어 사용자가 채식을 한다는 정보
Procedural	일을 처리하는 방법. 시스템 프롬프트나 작업 규칙이 여기에 해당한다

이 분류는 2023년 CoALA 논문이 인지과학의 기억 분류를 에이전트에 적용한 것이다.

03 계획

- 작업 분해: 목표를 하위 작업으로 나눈다. Chain-of-Thought로 단계를 풀어 쓰거나, Tree of Thoughts처럼 여러 경로를 비교하고 고르는 방법이 있다.
- Plan-and-Execute: 먼저 전체 계획을 세우고 단계별로 실행하며, 중간 결과에 따라 남은 계획을 고친다.
- 자기 성찰: 실행 결과를 스스로 평가하고 잘못된 점을 메모리에 남겨 다음 시도에 반영한다. 2023년 Reflexion이 대표적인 방법이다.

04 도구 사용

도구 사용은 function calling으로 구현한다. 개발자가 도구의 이름, 설명, 입력 형식을 정의해 두면 LLM은 필요할 때 어떤 도구를 어떤 인자로 부를지 JSON으로 출력하고, 실제 실행은 애플리케이션 코드가 맡는다.

```
{
  "name": "get_weather",
  "description": "도시의 현재 날씨를 조회한다",
  "parameters": {
    "type": "object",
    "properties": { "city": { "type": "string" } },
    "required": ["city"]
  }
}
```

LLM이 도구 호출을 출력하면 코드가 함수를 실행하고, 그 결과를 다시 LLM에 넘겨 다음 판단에 쓰게 한다. 도구 설명이 모호하면 모델이 엉뚱한 도구를 고르기 때문에 설명을 명확하게 써야 한다. 2024년 말 Anthropic이 공개한 MCP(Model Context Protocol)는 도구를 연결하는 방식을 표준화해서 한 번 만든 도구를 여러 에이전트에서 쓸 수 있게 했다.

05 AI Agent의 동작 방식

AI Agent는 인지, 판단, 행동을 한 번 하고 끝내지 않고 목표를 이룰 때까지 반복한다. 행동의 결과가 다시 다음 인지의 입력이 되는 루프 구조다.

순서	단계	여행 일정 에이전트 예시
01	인지	"다음 주 부산 1박 2일 일정 짜 줘"라는 요청을 받는다.
02	판단	날씨, 숙소, 교통을 먼저 알아봐야 한다고 판단한다.
03	행동	날씨 API와 숙소 검색 도구를 호출한다.
04	관찰	토요일에 비가 온다는 결과를 받고 실내 일정 위주로 계획을 고친다.
05	종료	필요한 정보가 다 모이면 최종 일정을 답한다.

루프가 끝나지 않으면 비용이 계속 들기 때문에 실제 구현에서는 최대 반복 횟수와 종료 조건을 함께 정한다. 1주차에서 본 ReAct는 이 루프를 생각과 행동을 번갈아 쓰는 프롬프트 형식으로 구현한 방법이다.

06 에이전트 유형

에이전트 유형은 Russell과 Norvig가 정리한 다섯 가지 분류를 따른다. 아래로 갈수록 판단에 쓰는 정보가 많아지고 더 복잡한 환경을 다룰 수 있다.

유형	판단 방식	예시
단순 반사	현재 입력만 보고 정해진 규칙대로 반응한다.	온도가 낮으면 켜지는 보일러
모델 기반 반사	지금 보이지 않는 환경 상태를 내부 모델로 추적하며 규칙대로 반응한다.	청소한 구역을 기억하는 로봇청소기
목표 기반	목표에 도달하는 행동을 찾는다.	목적지까지 가는 경로를 찾는 내비게이션
효용 기반	목표에 도달하는 여러 방법 중 효용 점수가 가장 높은 것을 고른다.	시간, 통행료, 혼잡도를 따져 경로를 고르는 내비게이션
학습	행동 결과로 받은 피드백을 바탕으로 스스로 성능을 높인다.	사용자 반응으로 추천을 고치는 추천 시스템

목표 기반과 효용 기반은 결과를 평가하는 방식이 다르다. 목표 기반은 목적지에 도착했는지 아닌지만 보고, 효용 기반은 도착한 경로 중 어느 쪽이 더 나은지를 점수로 비교한다. LLM 기반 에이전트는 이 유형 중 하나에 딱 들어가기보다 목표 기반을 바탕으로 효용 판단과 학습 요소를 섞어 쓰는 경우가 많다.

07 더 생각해 볼 질문

- 장기 메모리에 무엇을 저장하고 무엇을 버릴지 누가 정해야 하는가? 모든 내용을 저장하면 검색 품질이 떨어지고 개인정보 문제도 생겨서 저장 기준이 필요하다.
- 도구가 많아지면 에이전트 성능은 어떻게 되는가? 도구 수가 늘수록 모델이 알맞은 도구를 고르기 어려워져서, 필요한 도구만 골라 넘기는 방식이 연구되고 있다.

참고 자료: 서지영, 랭체인 & 랭그래프로 AI 에이전트 개발하기, 길벗 / Russell & Norvig, Artificial Intelligence: A Modern Approach / Lilian Weng, LLM Powered Autonomous Agents, 2023 / Sumers et al., Cognitive Architectures for Language Agents, 2023 / Shinn et al., Reflexion, 2023 / Anthropic, Model Context Protocol, 2024