4장 개인 복습 노트

신경망 학습

헷갈린 개념만 다시 잡기

『밑바닥부터 시작하는 딥러닝』 4장(107~146쪽)을 기준으로, 질문과 답변에서 실제로 헷갈렸던 부분을 짚어 정리한 복습 자료

이번 복습의 흐름

01 **손실 함수** — 왜 정확도 대신?

02 **기울기** — 무엇을 미분?

03 **경사하강법** — 언제 실패할까?

04 **일반화** — 무엇이 진짜 목표?

이 노트의 핵심

수식의 모양을 외우기보다, 지금 어떤 함수를 미분하고 무엇을 최소화하려는지 확인하자.

사용법 먼저 각 페이지의 "내가 헷갈린 지점"을 읽고, 계산 예제를 확인한 다음 마지막 페이지의 자가점검을 풀어 보자.

손실 함수와 정확도는 다르다

헷갈린 지점 ① “손실 함수에 마이너스를 붙이면 정확도와 비슷한 거 아냐?”

같은 정답, 다른 손실

정답이 숫자 5인 문제에서 두 모델 모두 5를 예측해도, 정답에 준 확률은 다를 수 있어.

비교	모델 A	모델 B
정답(5)의 예측 확률	60%	95%
이 한 문제의 정확도	100%	100%
교차 엔트로피 손실	-ln(0.60) = 0.511	-ln(0.95) = 0.051

중요한 구분

정확도는 맞혔는지를 세고, **손실**은 예측의 차이를 연속적인 수치로 나타낸다. 손실이 작아져도 분류 결과가 그대로면 정확도는 바뀌지 않을 수 있다.

마이너스(-) 기호가 등장하는 두 곳

교차 엔트로피의 -

정답의 예측 확률 p가 0~1이면 ln(p)는 0 이하. 손실 **-ln(p)**는 정답 확률이 커질수록 0에 가까워지도록 정의된다.

경사하강법의 -

기울기는 손실이 가장 빠르게 **증가**하는 방향이므로, 그 반대 방향으로 조금 움직이려고 **마이너스**를 붙인다.

$$w_{new} = w_{old} - \eta \cdot \nabla L$$

한 문장으로 기억

손실 최소화는 학습에 사용하는 **직접적인 목표**이고, 처음 보는 데이터에서 좋은 예측을 하는 것은 **궁극적인 목표(일반화)**다.

편미분은 함수에 따라 달라진다

헷갈린 지점 ② “편미분이 2x로 나왔으니 행렬의 각 값에 2를 곱하면 되지?”

> **네 계산이 맞았던 조건**
> 손실 함수가 **각 가중치 제곱의 합**이라면, 편미분은 2w가 된다. 하지만 **다른 손실 함수**에서는 다른 미분식이 나온다.

예제 1 | 단순한 제곱합

$$L(w1, w2) = w1^2 + w2^2$$

각각 편미분하면 **∂L/∂w1 = 2w1, ∂L/∂w2 = 2w2**. (3, 4)를 대입해 기울기 벡터 **(6, 8)**을 얻는다.

예제 2 | 계수가 달라진 경우

$$L(w1, w2) = 3w1^2 + 2w2^2$$

이번에는 기울기 **(6w1, 4w2)**. (2, 3)을 대입하면 **(12, 12)**. 핵심은 “먼저 함수에 맞게 미분 → 현재 값을 대입”하는 순서야.

가중치와 기울기 행렬의 크기는 같다

x (1×2) × W1 (2×3) → 은닉층 (1×3)

W1 = (2,3)이면 가중치 6개, 출력 원소 3개, 기울기 **dW1 = (2,3)**. 다음 층이 (3→2)라면 **W2 = (3,2)**, 편향은 **b1 = (3,), b2 = (2,)**.

> **왜 가중치마다 편미분할까?**
> 각 가중치는 손실에 미치는 영향이 서로 다르다. 한 매개변수의 기울기가 양수이고 다른 매개변수는 음수일 수 있으므로, 각각의 방향과 갱신량을 계산해야 한다.

수치 미분과 기울기 0

헷갈린 지점 ③ “기울기가 0이면 오류 아니야? 반드시 최소라는 뜻이야?”

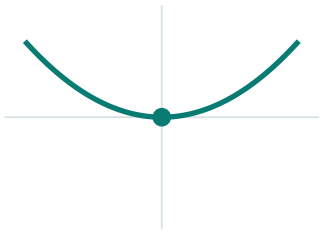
수치 미분: 식을 미분하지 않고도 기울기를 근사

$$f'(x) \approx [f(x+h) - f(x-h)] / (2h)$$

현재 x의 왼쪽과 오른쪽에서 함수 값을 계산해 변화율을 추정한다. 교재는 작은 h(예: 0.0001)를 사용하며, **정확한 도함수값이 아니라 근삿값**이라는 점에 주의하자.

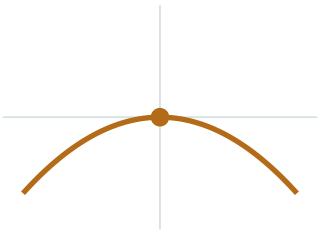
```
def numerical_diff(f, x):
    h = 1e-4
    return (f(x+h) - f(x-h)) / (2*h)
```

기울기가 0인 지점의 세 가지 모습



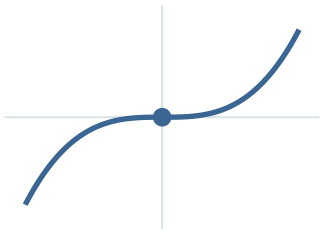
극솟값

$f(x) = x^2$



극댓값

$f(x) = -x^2$



수평 변곡점

$f(x) = x^3$

세 그래프는 모두 **x = 0에서 기울기 0**이지만, 그 지점이 모두 최솟값인 것은 아니다. 다변수 손실에서는 **안장점(saddle point)**도 가능하다.

기울기가 0이라는 것의 의미

일반적인 경사하강법에서 전체 기울기가 정확히 0이면 갱신량도 0이 되어 움직이지 않는다. 이는 프로그램 오류가 아니라 **현재 기울기만 보는 방법의 한계**다.

반대 방향이어도 손실이 커질 수 있다

헷갈린 지점 ④ "기울기가 양수면 음의 방향으로 가니까 항상 감소하지 않아?"

방향과 이동 거리는 다른 문제

$$L(w) = w^2 \quad | \quad w = 2 \quad | \quad dL/dw = 4$$

기울기 4는 **가까운 범위에서 왼쪽이 손실을 줄이는 방향**이라는 뜻이야. 하지만 너무 멀리 움직이면 최솟값 w=0을 지나칠 수 있어.

학습률 η	수정 후 w = 2 - 4η	새 손실 L(w)
0.10	1.6	2.56 (감소)
0.50	0	0 (최솟값)
1.00	-2	4 (변함없음)
1.50	-4	16 (증가)

학습률이 너무 큰 경우: 최솟값 통과



학습률의 균형

너무 크면 발산·진동할 수 있고, 너무 작으면 학습이 느리다. **음의 기울기 방향으로 아주 조금 이동할 때** 손실이 감소한다는 원리와 구분해 기억하자.

학습 코드를 흐름으로 읽기

헷갈린 지점 ⑤ “100개만 선택하면 나머지 데이터는 영원히 안 쓰이는 거야?”

미니배치: 60,000개 전체 대신 일부를 뽑아 갱신

예: 훈련 데이터 **60,000개** 중 **100개**를 뽑아 손실과 기울기를 계산하고 한 번 갱신한다. 다음 반복에서 또 100개를 뽑으므로, 앞서 선택하지 않았던 데이터도 나중에 사용될 수 있다.

교재 코드의 주의점

```
batch_mask = np.random.choice(train_size, batch_size)
x_batch = x_train[batch_mask]
t_batch = t_train[batch_mask]
```

위 **np.random.choice()**는 기본적으로 중복 추출을 허용한다. 같은 이미지가 다시 뽑힐 수 있고, 단순히 반복한다고 모든 이미지를 반드시 한 번씩 사용한다는 보장은 없다.

TwoLayerNet 학습 루프의 연결

1	**예측**	predict(x): 입력 → 은닉층 → 출력
2	**손실**	loss(x, t): 예측과 정답 비교
3	**기울기**	numerical_gradient(x, t): W1, b1, W2, b2 각각 편미분
4	**갱신**	params[key] -= learning_rate * grads[key]

코드에서 결국 수정하는 것은

W1, b1, W2, b2 등 **모든 학습 매개변수**다. 각 매개변수의 기울기는 해당 매개변수와 같은 shape를 가져야 한다.

훈련 손실 감소 ≠ 일반화 성능 향상

헷갈린 지점 ⑥ “손실이 줄면 개선된 거 아닌가? 시험 정확도가 떨어지는 이유는?”

학습의 직접적인 목표와 진짜 목적

직접적인 학습 목표

훈련 데이터에 대해 **손실을 줄이도록** 매개변수를 수정한다.

궁극적인 목표

처음 보는 데이터에서도 좋은 예측을 하도록 일반화한다.

대화에서 풀었던 모델 A/B 비교

항목	신경망 A	신경망 B
훈련 정확도	99%	94%
시험 정확도	80%	92%
현재 정보로 판단	과적합 의심	일반화 성능 우세

왜 B를 선택했을까?

A의 훈련 정확도는 더 높지만 새로운 데이터에 대한 시험 정확도가 낮다. 같은 조건의 평가라면 B가 일반화 성능이 더 좋다는 판단이 합리적이다.

시험 정확도가 떨어지는 원인은 하나만 있는 게 아니다

① **과적합**: 학습 데이터에 지나치게 맞춰져 새로운 데이터에서 성능이 나빠짐.

② **최적화의 문제**: 학습률이 너무 크거나 업데이트가 불안정함.

③ **평가 변동**: 표본과 우연한 변동에 따른 정확도 출렁임.

판단할 때 주의

훈련 정확도는 계속 상승하고 시험 정확도는 **지속적으로** 하락하는 패턴이면 과적합을 의심한다. 시험 정확도가 한 번 떨어진 사실만으로는 원인을 확정할 수 없다.

스터디 직전 3분 자가점검

답을 머릿속에서 먼저 말한 다음, 아래 정답과 비교해 보자.

01 손실이 0.5→0.3으로 감소했지만 정확도는 그대로다. 개선된 걸까?

정답: 손실이라는 학습 기준에서는 개선. 다만 새로운 데이터 성능 향상까지 보장하진 않는다.

02 $L(w1,w2)=3w1^2+2w2^2$, $(w1,w2)=(2,3)$. 기울기는?

정답: $\nabla L=(6w1, 4w2)=(12,12)$. 먼저 함수별로 편미분하고 대입한다.

03 W1=(2,3), W2=(3,2)일 때 기울기의 shape는?

정답: dW1=(2,3), dW2=(3,2). 각 가중치의 편미분 값이 하나씩 필요하다.

04 전체 기울기가 0이면 손실은 반드시 최소인가?

정답: 아니다. 극댓값, 수평 변곡점, 안장점 등도 가능하고 일반 경사하강법은 멈출 수 있다.

05 $L(w)=w^2$, $w=2$에서 학습률 1.5로 갱신하면?

정답: 기울기 4 → $w_{new}=2-1.5\times4=-4$ → 손실 4에서 16으로 증가.

06 미니배치를 여러 번 뽑으면 모든 훈련 데이터가 반드시 사용되나?

정답: 아니다. 교재의 기본 np.random.choice는 중복 추출을 허용하므로 빠진 데이터가 있을 수 있다.

07 훈련 정확도 99%, 시험 80%와 훈련 94%, 시험 92% 중?

정답: 같은 평가 조건에서 두 번째 모델이 더 나은 일반화 성능을 보인다.

한 줄 결론 손실을 계산하고 → 각 매개변수로 편미분하고 → 적절한 학습률로 갱신하되 → 일반화 성능을 따로 확인한다.