발표 자료 · 선형 회귀와 다항 회귀

범위: 『혼공머』 p.130–149

1. 길이가 달라도 예측 무게가 같다면?

농어 길이(cm)로 무게(g)를 예측하는 회귀.

입력	k-NN 회귀의 예측 (k=3)
50cm	약 1,033g
100cm	약 1,033g

이유: 두 입력이 같은 이웃 3마리를 선택 → 같은 무게 평균.

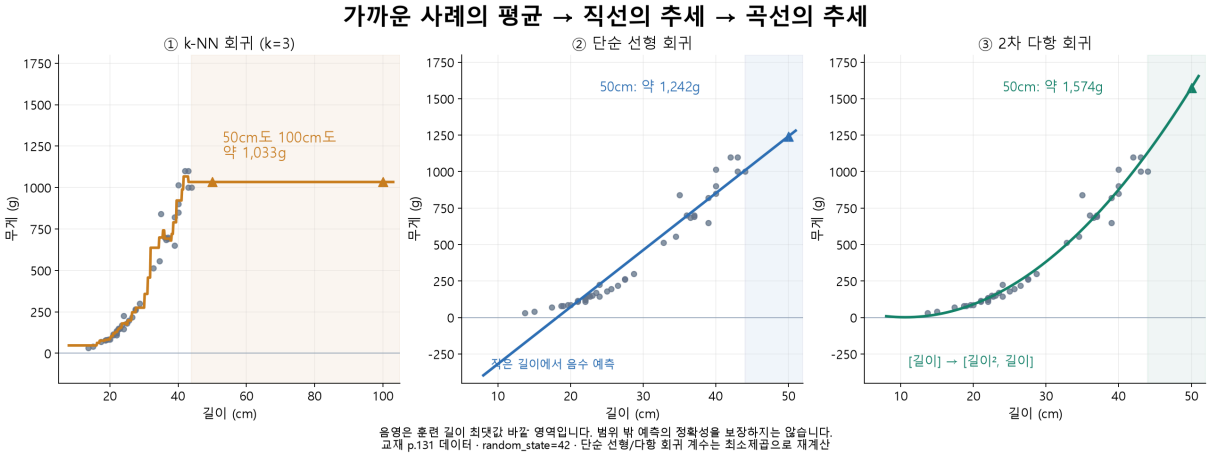
```
from sklearn.neighbors import KNeighborsRegressor

knr = KNeighborsRegressor(n_neighbors=3)
knr.fit(train_input, train_target)

knr.predict([[50]])   # 약 1033.33g
knr.predict([[100]])  # 약 1033.33g
```

한계: 범위 밖에서도 숫자는 반환하지만, 계속 증가하는 추세를 반영하기 어렵다.

2. 세 모델을 그림으로 보기



교재 데이터로 재계산한 비교 그래프. 왼쪽과 나머지 패널은 가로축 범위가 다르다. 음영은 훈련 길이 최댓값 바깥 영역.

k-NN	단순 선형 회귀	2차 다항 회귀
가까운 사례의 평균	직선의 추세를 학습	곡선의 추세를 학습
범위 밖에서 평평해짐	작은 길이에서 음수 예측	이 데이터의 곡선 경향을 더 잘 표현

3. 선형 회귀: 직선의 기울기와 절편 학습

예측 무게 = a × 길이 + b

값	의미	저장 위치
a: 기울기·계수	길이 1cm 증가에 따른 모델의 예측 무게 변화	`coef_`
b: 절편	길이가 0일 때 직선 식의 값	`intercept_`

학습: 실제값과 예측값의 차이를 제곱해 더한 값이 작아지도록 a, b를 찾는다.

모델 파라미터: 데이터에서 학습한 계수·절편.
하이퍼파라미터: 학습 전에 정하는 설정. 예: k-NN의 k.

```
from sklearn.linear_model import LinearRegression

linear = LinearRegression()
linear.fit(train_input, train_target)

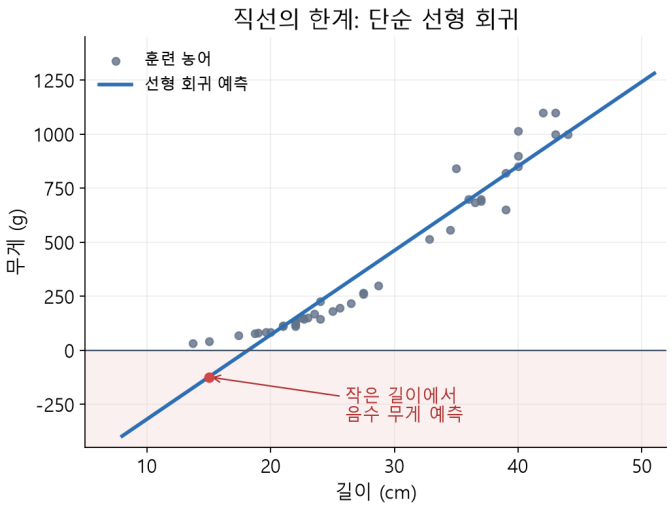
print(linear.coef_)           # 약 [39.0171]
print(linear.intercept_)      # 약 -709.0186
print(linear.predict([[50]]))  # 약 1241.84g
```

학습한 관계식: 예측 무게 ≈ 39.0171 × 길이 − 709.0186

직선을 연장해 범위 밖에서도 변하는 값을 예측한다. **정확성이 보장되는 것은 아니다.**

4. 직선으로 충분할까?

- 데이터는 길이가 커질수록 무게가 더 가파르게 증가하는 곡선 경향.
- 직선은 길이 1cm당 무게 증가량이 항상 일정.
- 이 직선은 15cm에서 약 **−125g**을 예측.



같은 훈련 농어 데이터에 학습한 선형 회귀. 빨간 점은 15cm에서의 모델 예측.

그래프에서 볼 부분

- 회색 점: 실제 훈련 농어.
- 파란 선: 직선 모델의 예측.
- 빨간 영역: 무게가 0g보다 작은 구간.
- 작은 길이에서 파란 선이 0g 아래로 내려간다.

직선의 표현력이 부족하다 → 곡선으로 표현해 보자.

5. 다항 회귀: 길이²를 새 특성으로

예측 무게 = a × 길이² + b × 길이 + c

길이 하나	새 입력: [길이², 길이]
[20]	[400, 20]
[50]	[2500, 50]

```
train_poly = np.column_stack((train_input ** 2, train_inpu
t))
test_poly = np.column_stack((test_input ** 2, test_input))

poly = LinearRegression()
poly.fit(train_poly, train_target)

print(poly.predict([[50 ** 2, 50]]))  # 약 1573.98g
```

- 샘플 수 유지, 특성 수 **1개 → 2개**.
- 훈련 입력 **(42, 1) → (42, 2)**.
- 타깃은 **원래 무게 그대로**.
- 예측할 때도 **같은 특성·같은 순서** 적용.

6. 곡선인데 왜 LinearRegression일까?

길이에 대해서는 곡선, 학습하는 계수에 대해서는 선형.

길이²를 특성 1, 길이를 특성 2로 보면:

예측 무게 = a × 특성 1 + b × 특성 2 + c

속성	교재의 값	대응
`poly.coef_`	약 [1.0143, −21.5579]	길이² 계수, 길이 계수
`poly.intercept_`	약 116.0502	절편

7. 모델 성능 비교

```
linear.score(test_input, test_target)
poly.score(test_poly, test_target)
```

모델	훈련 R^2	테스트 R^2	50cm 예측
직선	0.9398	0.8248	약 1,242g
2차 다항	0.9707	0.9776	약 1,574g

같은 데이터 분할에서 훈련·테스트 R^2가 모두 개선됐다.

R^2는 평균으로만 예측하는 기준 대비 제곱오차를 얼마나 줄였는지 나타낸다. **0.9776은 정답률 97.76%라는 뜻이 아니다.**

테스트 점수가 훈련보다 조금 높다는 사실만으로 과소적합을 확정하지 않는다.

8. 핵심 정리



이웃 평균 → 직선 → 곡선
k-NN: 가까운 샘플의 타깃 평균 → 범위 밖 증가 추세 반영에 한계.
선형 회귀: 기울기·절편 학습 → 직선으로 추세 표현.
다항 회귀: 제곱 특성 추가 → 곡선 관계 표현 및 이번 테스트 성능 개선.